

Antigravity الدليل الشامل لإدارة نافذة السياق وترشيد التوكنز في

Antigravity IDE و CLI الدليل العملي لحوكمة الجلسات، كبح تدهور التركيز، وخفض خط الأساس في بيئة

الخلاصة التنفيذية والهدف المعماري

مع تصحيح agcli، والأداة الطرفية Antigravity IDE (Context Window) يقدم هذا المستند استراتيجية هندسية متكاملة لإدارة نافذة السياق المفاهيم الخاطئة حول 'أمان المليون توكن'، وتوضيح الركائز الأربع لحماية الذاكرة ومنع تشتت النماذج وتسريع الأداء البرمجي.

(The 1M Illusion) 'أولاً: تشريح المشكلة — وهم الأمان في 'المليون توكن

هذه (1M Tokens) بنافذة سياق ضخمة تتسع لـ 1,048,576 توكن Gemini 3.8 Flash (High) على نموذج Antigravity يعتمد محرك توفر مساحة رحبة، لكنها توقع المطورين في فخين معماريين خطيرين (5 Claude Code أضعاف) السعة الهائلة

توكن، تبدأ قدرة النموذج اللغوي على k إلى 500 كلمة تجاوزت الجلسة 400 (Context Rot): ظاهرة تدهور التركيز وضياح التفاصيل 1. استرجاع التفاصيل الدقيقة بالانخفاض، مما يؤدي لنسيان القيود المعمارية الصارمة واللجوء لحلول سطحية وتكرار أخطاء برمجية سابقة.

محلية SQLite يسجل المحرر كل خطوة واستدعاء أداة في قاعدة بيانات: (RAM & SQLite Bloat) تضخم الذاكرة العشوائية للمحرر 2. انتفاخ الجلسة يضخم قاعدة البيانات إلى أكثر من 40 ميغابايت ويرفع استهلاك الذاكرة. (~/.gemini/antigravity-ide/conversations/*.db) (errno=1455) مما يبطئ واجهة المحرر ويسبب أخطاء الذاكرة الافتراضية للويندوز، GB العشوائية إلى 2.5.

(Tool Call Multiplier) ثانياً: الحقيقة الهندسية — مضاعف استدعاء الأدوات

الخطر الأكبر في إدارة السياق ليس الوصول لسقف المليون، بل التكلفة التراكمية في كل دورة عمل:

- يعيد المحرك إرسال كامل سياق المحادثة السابق من البداية (Tool Call) بنية استدعاء النماذج: في كل خطوة تفكير أو استدعاء لأداة برمجية.
- الحسبة الرياضية الصادمة: إذا كانت جلستك منتفخة بـ 200,000 توكن، ونفذ الوكيل 15 أداة برمجية لإنجاز ميزة معينة، فإن إجمالي التوكنز المعالجة والمحسوبة على كوتا الحساب هو: $15 \times 200,000 = 3,000,000$ ملايين توكن تم حرقها في مهمة واحدة! بينما إبقاء الجلسة عند 80,000 توكن. توكن فقط، محققاً وفراً قدره 1.8 مليون توكن M يستهلك 1.2.

Antigravity (The Baseline) ثالثاً: الركيزة الأولى — خفض خط الأساس في

عند فتح أي جلسة جديدة، يبدأ مؤشر الاستهلاك فعلياً من 110,000 إلى 135,000 توكن (ما يعادل 11% إلى 13% من المليون (محجوزة للتعليمات الأساسية والأدوات والمهارات المحقونة. يوضح الجدول التالي المكونات المهدرة وكيفية خفضها

المكون المهدر	الحجم التقريبي	الإجراء والتوصية الهندسية
غير المستخدمة (مثل MCP سيرفرات + أداة hostinger بـ 120)	توكن 25k - 35k	وحصرها في بيئات الويب فقط mcp_config.json تعطيلها من ملف
المهارات الفائضة (حزم الكيمياء والأحياء (وووردبريس	توكن 20k - 30k	لحذف المهارات الزائدة (3 Hook) تشغيل خطاف التخصيص الذكي تلقائياً
قواعد الدستور المتضخمة داخل AGENTS.md	توكن 15k - 20k	MEMORY_STORE.md عزل الدروس المستفادة وحصرها في اللامركزي
ملفات السياق المحقون غير المفلترة	توكن 10k - 15k	وأرشفة القيود ACTIVE_CONTEXT_INJECTION.md تنقيح المنتهية

!توكن، موفراً أكثر من 65,000 توكن في كل دورة طوال اليوم 70k- إلى نحو 65k الأثر المباشر: ينخفض خط الأساس فوراً من ~135

Antigravity IDE و CLI (agcli) رابعاً: الركيزة الثانية — المقارنة المعمارية بين

:وجهين تشغيليين يجب الفصل التام بينهما Antigravity يمتلك، (Hook 22) CLIs في إطار حوكمة أسطول الـ

وجه المقارنة	Antigravity IDE (Workbench)	Antigravity CLI (agcli run)
طبيعة العمل	بيئة التطوير الرسومية التفاعلية للمطور.	(Headless). المنفذ الطرفي الذاتي غير التفاعلي
الاستخدام الأمثل	Artifacts والـ Diffs التخطيط المعماري ومراجعة الـ.	توليد الأكواد، وتحديث الذاكرة، UI بناء شاشات الـ.
استهلاك الذاكرة	بسبب (2.0GB – 2.5GB RAM) مرتفع Electron.	منخفض جداً ومعزول ويحرر الذاكرة فور الانتهاء
إدارة السياق	SQLite. محادثة ممتدة تتراكم في قاعدة بيانات.	سياق مؤقت ينتهي مع انتهاء الأمر
القاعدة المعمارية	الآلية إليها منعاً للنسخ CLI يُحظر توجيه أوامر الـ اليدوي.	المنفذ المعتمد للتفويض المباشر الذاتي من الأسطول

M خامساً: الركيزة الثالثة — عتبات الاستهلاك والتصفير في نافذة الـ 1

:بناءً على منحني تركيز النماذج، يتم تقسيم نافذة المليون إلى أربعة نطاقات تشغيلية دقيقة:

- أقصى درجات الذكاء والتركيز وانعدام تام — (Sweet Spot) منطقة الأداء الفائق: (%توكن 0/ - 30 0k - 300) النطاق الأخضر
 - منطقة الإنتاجية المستقرة — استقرار عالي في الأداء مع ضرورة الالتزام: (%توكن 30/ - 60 600k - 300k) النطاق الأصفر
 - منطقة التحذير — بداية تشتت التركيز. التوجيه الهندسي: إنهاء الميزة الحالية: (%توكن 60/ - 80 800k - 600k) النطاق البرتقالي
 - منطقة الخطر والتصفير الإلزامي — يُحظر بدء أي ميزة جديدة. يتم تطبيق خطاف التصفير: (%توكن > 80/ > 800k) النطاق الأحمر
- وبدء جلسة جديدة نظيفة CURRENT_STATE.md وتجميد الحالة في (Hook 25) الاستراتيجي

ag-context سادساً: الركيزة الرابعة — المراقبة اللحظية باستخدام أداة

Antigravity: تم ابتكار وبناء أداة طرفية متخصصة ومدمجة في النظام لقراءة استهلاك التوكنز لحظياً مباشرة من محرك

⚡ ag-context الأوامر التشغيلية اليومية لأداة

1. ag-context: عرض الحالة الفورية.
2. ag-context -w: شاشة المراقبة الحية في الوقت الفعلي (تحديث تلقائي كل 3 ثوانٍ).
3. ag-context -H 5: فحص تاريخ استهلاك التوكنز لآخر 5 خطوات.
4. ag-context -j: للتكامل مع السكريبتات والوكلاء JSON مخرجات.

سابعاً: الركيزة الخامسة — قواعد النظافة اليومية لكبح انتفاخ السياق

1. لقراءة ملفات كاملة تتجاوز 100 سطر. يجب دائماً استخدام معاملي `view_file` يُحظر استدعاء **(Slice Notation)** القراءة المجزأة للملفات. لقراءة المقطع المستهدف فقط `StartLine` و `EndLine`.
2. لإعادة كتابة ملفات كاملة `write_to_file` لتعديل الأسطر المحددة وتجنب `replace_file_content` الاستبدال الموضعي: اعتماد.
3. توكن عند طباعتها في الكونسول. القاعدة: توجيه k إلى 30 kتلتهم من 10 NPM أو Gradle حظر طباعة مخرجات البناء الخام: مخرجات. وقراءة سطور الخطأ فقط `(./gradlew ... > build.log)` المخرجات لملف خارجي.
4. تجميع الاستفسارات والمهام في رسالة واحدة منسقة يوفر دورات كاملة من إعادة إرسال سياق المحادثة السابق: **(Batching)** تجميع الطلبات.

ثامناً: الخلاصة التنفيذية وقائمة الإجراءات الفورية

1. (توكن k-35k يوفر 25) `mcp_config.json` الزائدة في MCP تعطيل خوادم.
2. (توكن k-30k يوفر 20) لحذف المهارات غير المستخدمة (Hook 3) تشغيل خطاف التخصيص الذكي.
3. `ag-context` المتابعة اليومية لنسبة الامتلاء عبر أمر.
4. توجيه مخرجات البناء للملفات لتفادي قفزات التوكنز المفاجئة.
5. (Sweet Spot) التصفير الاستراتيجي عند 60% إلى 70% للبقاء دائماً في منطقة الأداء الفائق.